

Distribuições BGEV

Seja $y \sim \text{GEV}(\xi, \mu, \sigma)$. Assim, a função de distribuição acumulada de y é dada por

$$F(y; \xi, \mu, \sigma) = \begin{cases} \exp\left\{-\left[\zeta + \xi\left(\frac{y-\mu}{\sigma}\right)\right]^{-1/\xi}\right\}, & \xi \neq 0 \\ \exp\left\{-\exp\left[-\left(\frac{y-\mu}{\sigma}\right)\right]\right\}, & \xi = 0, \end{cases}$$

$\xi \in \mathbb{R}$
 $\mu \in \mathbb{R}$
 $\sigma > 0$

onde que para $\xi \neq 0$ é necessário ter
 $\zeta + \xi\left(\frac{y-\mu}{\sigma}\right) > 0$, e para $\xi = 0$ tem-se $y \in \mathbb{R}$.

Para definir a distribuição GEV bimodal (BGEV), considere a seguinte transformação na variável y :

$$T_{\mu, \delta}(y) = (y - \mu) / (\delta - \mu), \quad \delta > -\mu, \quad \mu \in \mathbb{R}.$$

Dai, a distribuição BGEV é obtida a partir da avaliação da função de distribuição de $\text{GEV}(\xi, 0, \sigma)$ no ponto $T_{\mu, \delta}(y)$, isto é,

$$F(T_{\mu, \delta}(y); \xi, 0, \sigma, \delta) =$$

$$\begin{aligned}
 & = \left\{ \exp \left\{ - \left[1 + \xi \left(\frac{T_{u,\delta}(y)}{\sigma} \right) \right]^{-\frac{1}{\xi}} \right\}, \xi \neq 0 \right. \\
 & \quad \left. \exp \left\{ - \exp \left[- \left(\frac{T_{u,\delta}(y)}{\sigma} \right) \right] \right\}, \xi = 0 \right\} \\
 & \quad \text{notar } Y \sim \text{B6EV}(\xi, \mu, \sigma, \delta) \\
 & \quad \text{onde que} \\
 & \quad \left\{ \begin{array}{l} y \in \left[\mu - \left(\frac{\sigma}{\xi} \right)^{\frac{1}{\xi+1}}, \infty \right), \text{ se } \xi > 0, \\ y \in (-\infty, \mu + \left| \frac{\sigma}{\xi} \right|^{\frac{1}{\xi+1}}], \text{ se } \xi < 0, \\ y \in \mathbb{R}, \text{ se } \xi = 0. \end{array} \right.
 \end{aligned}$$

Mostra-se que a função quantílica de $Y \sim \text{B6EV}(\xi; \mu, \sigma, \delta)$ é dada por

$$Q(T; \xi, \mu, \sigma, \delta) = \text{seval} \left(-\ln(-\ln(T)) \right) \left| \frac{1}{\xi+1} + \mu \right| + \mu,$$

em que $0 < T < 1$.

A partir da função quantílica, obtemos que ③

$$\mu = q_T - \text{sinal}(-\ln(-\ln(T))) \left| -\sigma \ln(-\ln(T)) \right|^{\frac{1}{\delta+1}},$$

em que q_T denota o T -ésimo quantil da distribuição BGEV.

Se $T=0,5$, então $m = q_{0,5}$ é a mediana da distribuição BGEV. Lembre-se que μ é ^{apenas} um parâmetro de localização, e portanto não representa a média ou a mediana da distribuição. Nesse sentido, para obtermos a modelagem de dados com ^{uma} interpretação direta se torna interessante reparametrizar a distribuição BGEV em termos de sua mediana.

Veja que se $T=0,5$, então

$$m = m - \text{sinal} \left(\frac{0,3665 > 0}{-\ln(-\ln(0,5))} \right) \left| -\sigma \ln(-\ln(0,5)) \right|^{\frac{1}{\delta+1}}$$

$$\mu = m - \left(-\sigma \ln(-\ln(0,5)) \right)^{\frac{1}{\delta+1}}$$

com $\sigma > 0$ e $\delta > -1$. Daí, tem-se que

mediana depende de μ, σ e δ .

$$m = \mu + \left(-\sigma \ln(-\ln(0,5)) \right)^{\frac{1}{\delta+1}}, \quad m \in \mathbb{R}.$$

Logo, quanto maior for μ maior será a mediana m .

A função de distribuição da BGEV reparametrizada fica dada por

$$F(T_{m,\delta}(y); \xi, 0, \sigma, \delta) = \begin{cases} \exp\left\{-\left[1 + \xi \left(\frac{T_{m,\delta}(y)}{\sigma}\right)\right]\right\}, & \xi \neq 0 \\ \exp\left\{-\exp\left[-\left(\frac{T_{m,\delta}(y)}{\sigma}\right)\right]\right\}, & \xi = 0 \end{cases}$$

com o suporte tendo a mesma esfera, porém substituindo m por \bar{m} . Denotaremos por $y \sim \text{BGEV}(\xi, m, \sigma, \delta)$.

Regressão

considere n realizações independentes de tal forma que $y_i \stackrel{\text{ind}}{\sim} \text{BGEV}(\xi, m_i, \sigma, \delta)$, $i = 1, 2, \dots, n$, e suponha a seguinte estrutura de regressão para a mediana:

$$g(m_i) = \gamma_i = \sum_{j=1}^p x_{ij} \beta_j = \tilde{x}_i \beta,$$

em que $\beta = (\beta_1, \beta_2, \dots, \beta_p)^T \in \mathbb{R}^p$ é um vetor de parâmetros desconhecidos associado à mediana m ,

$\tilde{x}_i = (x_{i1} \ x_{i2} \dots x_{ip})^T \in \mathbb{R}^P$ é o vetor de (5)
 valores conhecidos das p variáveis explicativas
 para a i -ésima observação, e $g(\cdot)$ é uma
 função de ligação contínua, estritamente mono-
 tonia e duas vezes diferenciável.

Neste cenário, as funções de ligação mais utili-
 -zadas são

1) Identidade: $g(z) = z$, $z \in \mathbb{R}$.

2) Logarítmica: $g(z) = \frac{\ln(z)}{\ln(z)}$, $z > 0$.

Estimação

O vetor da regressão $\beta = (\beta_1 \dots \beta_p)$ e os
 parâmetros ξ, ς e δ são desconhecidos e devem
 ser estimados. Para tanto, pode-se utilizar
 o método de máxima verossimilhança.

O logaritmo da função de verossimilhança
 para o vetor de parâmetros $\theta = (\beta^+, \xi, \varsigma, \delta) \in \mathbb{R}^{P+3}$
 é dado por $l(\theta) \rightarrow$ logaritmo da densidade
 BGEV($\xi, m, \varsigma, \delta$)

$$l(\theta) = \sum_{i=1}^n \log [f(t_{mi}, s(y_i); \xi, \varsigma, \delta)]$$

em que $\neq (T_{mi,s}(y_i); \xi, 0, s)$ e

⑥

- para $\xi \neq 0$:

$$\frac{1}{\sigma} \left[1 + \xi \left(\frac{T_{mi,s}(y_i)}{\sigma} \right) \right]^{-\frac{1}{\xi} - 1} \exp \left\{ - \left[1 + \xi \left(\frac{T_{mi,s}(y_i)}{\sigma} \right) \right]^{-\frac{1}{\xi}} \right\} T_{mi,s}(y_i)$$

- para $\xi = 0$:

$$\frac{1}{\sigma} \exp \left\{ - \frac{T_{mi,s}(y_i)}{\sigma} \right\} \exp \left\{ - \exp \left\{ - \frac{T_{mi,s}(y_i)}{\sigma} \right\} T_{mi,s}(y_i) \right\}$$

Dai, segue (que é dada por

- $\xi \neq 0$:

$$-\log(\xi) - \left(\frac{1}{\xi} + 1 \right) \log \left[1 + \xi \left(\frac{T_{mi,s}(y_i)}{\sigma} \right) \right] - \left[1 + \xi \left(\frac{T_{mi,s}(y_i)}{\sigma} \right) \right]^{-\frac{1}{\xi}} + \log [T_{mi,s}(y_i)]$$

- $\xi = 0$:

$$-\log(\xi) - \frac{T_{mi,s}(y_i)}{\sigma} - \exp \left\{ - \frac{T_{mi,s}(y_i)}{\sigma} \right\} + \log [T_{mi,s}(y_i)]$$

7

Assim, o logaritmo da função de verossimilhança para θ e ξ

- $\xi \neq 0$:

$$\ell(\theta) = -n \log(\sigma) - \left(\frac{1}{\xi} + 1 \right) \sum_{i=1}^n \log \left[1 + \xi \left(\frac{T_{mi,s}(y_i)}{\sigma} \right) \right] \\ + \sum_{i=1}^n \left\{ \log \left[T_{mi,s}(y_i) \right] - \left[1 + \xi \left(\frac{T_{mi,s}(y_i)}{\sigma} \right) \right]^{-1/\xi} \right\}$$

- $\xi = 0$:

$$\ell(\theta) = -n \log(\sigma) + \sum_{i=1}^n \left\{ \log \left[T_{mi,s}(y_i) \right] - \frac{T_{mi,s}(y_i)}{\sigma} - \exp \left\{ -\frac{T_{mi,s}(y_i)}{\sigma} \right\} \right\}$$

Próximo passo é obter o vetor escore: